


Entrega 2: Izabella e Patrick dos Santos

• **Objetivo:** Aprimoramento do nosso conhecimento da técnica estatística regressão a fim de estudarmos a relação matemática existente entre nossas variáveis de interesse.

• **Desenvolvimento:**

→ Obter os estimadores $\hat{\beta}_0$ e $\hat{\beta}_1$ (estimativa dos valores mínimos do Erro total):

Para achar esses estimadores, é preciso entender os componentes de um gráfico da relação linear de duas variáveis: Assim para facilitar o entendimento iremos explicar cada componente gráfico:



y_i = valor da variável resposta

x_i = valor da variável explicativa

β_0 = parâmetro do intercepto

β_1 = parâmetro do coeficiente angular

\hat{y}_i = regressão de Y em X

ϵ_i = erro estocástico

$i = 1, 2, 3, \dots, n$

n = tamanho da amostra

Com isso podemos começar a estimar os valores de $\hat{\beta}_0$ e $\hat{\beta}_1$, a partir de uma amostra de n pares de valores (x_i, y_i) com i igual à $1, \dots, n$, que são os n pontos de um gráfico. Supondo que é traçada uma reta que passa o mais próximo possível de todos os pontos, essa reta será definida por $\beta_0 + \beta_1 x$. Existe também uma diferença entre os pontos e a reta, que é chamado de desvio ou erro estocástico. Esse erro pode ser definido por $\epsilon_i = y_i - (\beta_0 + \beta_1 x_i)$.

Aqui visamos obter valores estimados de β_0 e β_1 , sempre buscando valores mínimos para o desvio e_i . Uma técnica muito eficiente para este cálculo é o Método dos Mínimos Quadrados. Nele, minimizamos a soma dos quadrados mínimos na seguinte expressão:

$$L = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

a expressão é elevada ao quadrado para que os valores seja sempre positivos

As estimativas para os parâmetros β_0 e β_1 precisam satisfazer as expressões derivativas:

$$\left. \frac{\partial L}{\partial \beta_0} \right|_{\hat{\beta}_0, \hat{\beta}_1} = -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$$

$$\left. \frac{\partial L}{\partial \beta_1} \right|_{\hat{\beta}_0, \hat{\beta}_1} = -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) \cdot x_i = 0$$

Igualamos à 0, pois substituímos por $\hat{\beta}_0$ e $\hat{\beta}_1$, que são valores particulares de L

Após simplificar essas equações, iremos chegar às novas equações que são chamadas de Equações Normais de Mínimos Quadrados

$$\begin{cases} n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n x_i = \sum_{i=1}^n y_i \\ \hat{\beta}_0 \sum_{i=1}^n x_i + \hat{\beta}_1 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i y_i \end{cases}$$

Equações Normais de Mínimos Quadrados

Resolvendo o sistema de equações descobrimos que:

$$\hat{\beta}_0 = \frac{\sum_{i=1}^n y_i}{n} - \hat{\beta}_1 \frac{\sum_{i=1}^n x_i}{n} = \bar{Y} - \hat{\beta}_1 \bar{X}$$

Substituindo o valor de $\hat{\beta}_0(\bar{Y} - \hat{\beta}_1 \bar{X})$ na segunda equação das Equações Normais de Mínimos Quadrados, temos:

$$\begin{aligned}\hat{\beta}_1 \sum_{i=1}^n x_i^2 &= \sum_{i=1}^n x_i y_i - \hat{\beta}_0 \sum_{i=1}^n x_i \\ &= \sum_{i=1}^n x_i y_i - (\bar{Y} - \hat{\beta}_1 \bar{X}) \sum_{i=1}^n x_i \\ &= \sum_{i=1}^n x_i y_i - \bar{Y} \sum_{i=1}^n x_i + \bar{X} \hat{\beta}_1 \sum_{i=1}^n x_i \\ &= \sum_{i=1}^n x_i y_i - n \bar{X} \bar{Y} + n \hat{\beta}_1 \bar{X}^2\end{aligned}$$

$$\hat{\beta}_1 \left(\sum_{i=1}^n x_i^2 - n \bar{X}^2 \right) = \sum_{i=1}^n x_i y_i - n \bar{X} \bar{Y}$$

$$\therefore \hat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i - n \bar{X} \bar{Y}}{\sum_{i=1}^n x_i^2 - n \bar{X}^2} = \frac{\sum_{i=1}^n (x_i - \bar{X}) y_i}{\sum_{i=1}^n (x_i - \bar{X}) x_i} = \frac{\sum_{i=1}^n (x_i - \bar{X}) (y_i - \bar{Y})}{\sum_{i=1}^n (x_i - \bar{X})^2}$$

Assim conseguimos obter e definir os estimadores $\hat{\beta}_0$ e $\hat{\beta}_1$, eles também são chamados de Estimadores de Mínimos Quadrados.

→ Suposições

Supomos que a distribuição dos erros siga uma distribuição normal e seu valor esperado seja o menor possível, no caso, 0. Supomos também que a variância seja constante e um método de checar se tal suposição é adequada, é pela técnica de estimação da variância residual.

→ Hipóteses

A hipótese nula define que não há correlação entre as variáveis X e Y :

$$H_0: \beta_1 = 0$$

A hipótese alternativa define que há correlação entre as nossas variáveis X e Y :

$$H_1: \beta_1 \neq 0$$

Caso a hipótese nula seja rejeitada, significa que a variável X interfere no resultado da variável Y . Caso ela não seja rejeitada, significa que existe a possibilidade de que a variável X não interfira na Y assim como há possibilidades de que ela interfira.