


## Entrega 2: Izabella e Patrick dos Santos

• **Objetivo:** Aprimoramento do nosso conhecimento da técnica estatística regressão a fim de estudarmos a relação matemática existente entre nossas variáveis de interesse.

• **Desenvolvimento:**

→ Obter os estimadores  $\hat{\beta}_0$  e  $\hat{\beta}_1$  (estimativa dos valores mínimos do Erro total):

Para achar esses estimadores, é preciso entender os componentes de um gráfico da relação linear de duas variáveis: Assim para facilitar o entendimento iremos explicar cada componente gráfico:



$y_i$  = valor da variável resposta

$x_i$  = valor da variável explicativa

$\beta_0$  = parâmetro do intercepto

$\beta_1$  = parâmetro do coeficiente angular

$\hat{y}_i$  = regressão de Y em X

$\epsilon_i$  = erro estocástico

$i = 1, 2, 3, \dots, n$

$n$  = tamanho da amostra

Com isso podemos começar a estimar os valores de  $\hat{\beta}_0$  e  $\hat{\beta}_1$ , a partir de uma amostra de  $n$  pares de valores  $(x_i, y_i)$  com  $i$  igual à  $1, \dots, n$ , que são os  $n$  pontos de um gráfico. Supondo que é traçada uma reta que passa o mais próximo possível de todos os pontos, essa reta será definida por  $\beta_0 + \beta_1 x$ . Existe também uma diferença entre os pontos e a reta, que é chamado de desvio ou erro estocástico. Esse erro pode ser definido por  $\epsilon_i = y_i - (\beta_0 + \beta_1 x_i)$ .



Aqui visamos obter valores estimados de  $\beta_0$  e  $\beta_1$ , sempre buscando valores mínimos para o desvio  $e_i$ . Uma técnica muito eficiente para este cálculo é o Método dos Mínimos Quadrados. Nele, minimizamos a soma dos quadrados mínimos na seguinte expressão:

$$L = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

a expressão é elevada ao quadrado para que os valores seja sempre positivos

As estimativas para os parâmetros  $\beta_0$  e  $\beta_1$  precisam satisfazer as expressões derivativas:

$$\left. \frac{\partial L}{\partial \beta_0} \right|_{\hat{\beta}_0, \hat{\beta}_1} = -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$$

$$\left. \frac{\partial L}{\partial \beta_1} \right|_{\hat{\beta}_0, \hat{\beta}_1} = -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) \cdot x_i = 0$$

Igualamos à 0, pois substituímos por  $\hat{\beta}_0$  e  $\hat{\beta}_1$ , que são valores particulares de L

Após simplificar essas equações, iremos chegar às novas equações que são chamadas de Equações Normais de Mínimos Quadrados

$$\begin{cases} n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n x_i = \sum_{i=1}^n y_i \\ \hat{\beta}_0 \sum_{i=1}^n x_i + \hat{\beta}_1 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i y_i \end{cases}$$

Equações Normais de Mínimos Quadrados

Resolvendo o sistema de equações descobrimos que:

$$\hat{\beta}_0 = \frac{\sum_{i=1}^n y_i}{n} - \hat{\beta}_1 \frac{\sum_{i=1}^n x_i}{n} = \bar{Y} - \hat{\beta}_1 \bar{X}$$